學號：R06922097 系級： 資工碩一 姓名：鄭雅文

1. **(1%) 請說明你實作的 RNN model，其模型架構、訓練過程和準確率為何？**

答：先用 Word2Vec 得到每個字的向量，再把 tokenize 的編號轉成 Word2Vec 的 index，用 keras 預設的 embedding 層。

模型架構：

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
embedding_1 (Embedding)      (None, None, 128)         2560000
_________________________________________________________________
lstm_1 (LSTM)                (None, 128)               131584
_________________________________________________________________
dense_1 (Dense)              (None, 1)                 129
=================================================================
Total params: 2,691,713
Trainable params: 2,691,713
Non-trainable params: 0
_________________________________________________________________
```

訓練過程和準確率：

```
200000/200000 [==============================] - 743s 4ms/step - loss: 0.4589 - acc: 0.7829
Epoch 2/3
200000/200000 [==============================] - 732s 4ms/step - loss: 0.4073 - acc: 0.8133
Epoch 3/3
200000/200000 [==============================] - 713s 4ms/step - loss: 0.3834 - acc: 0.8265
```

Kaggle: public: 0.81260

private: 0.81113

2. **(1%) 請說明你實作的 BOW model，其模型架構、訓練過程和準確率為何？**

答：與上個模型架構差不多，但把 tokenize 的 num_words 設為 100，不然 input 會太大。用 texts_to_matrix 轉成 BOW 的 input。

模型架構：

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
embedding_1 (Embedding)      (None, None, 128)         2560000
_________________________________________________________________
lstm_1 (LSTM)                (None, 128)               131584
_________________________________________________________________
dense_1 (Dense)              (None, 1)                 129
=================================================================
Total params: 2,691,713
Trainable params: 2,691,713
Non-trainable params: 0
_________________________________________________________________
```

訓練過程和準確率：

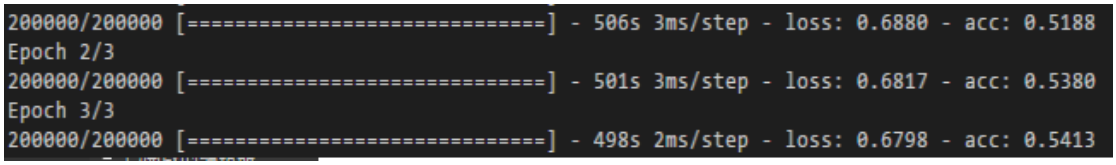

Kaggle: public: 0.53132

Private: 0.53166

3. **(1%) 請比較 bag of word 與 RNN 兩種不同 model 對於"today is a good day, but it is hot"與"today is hot, but it is a good day"這兩句的情緒分數，並討論造成差異的原因。**

答：

	"today is a good day, but it is hot"	"today is hot, but it is a good day"
BOW	0.49039897	0.48992708
RNN	0.31660247	0.94093776

因為 RNN 有考慮每個句子中的單字順序，BOW 只考慮出現的字，沒有順序的差別，所以幾乎同樣的字但順序不同、意思不同的話，RNN 比較分辨得出來。

4. **(1%) 請比較"有無"包含標點符號兩種不同 tokenize 的方式，並討論兩者對準確率的影響。**

答：

有標點符號：token = Tokenizer(num_words = 5000,filters='\t\n')

無標點符號：token = Tokenizer(num_words = 5000)

因為 filters 預設為'!"#$%&()*+,-./:;<=>?@[\\]^_`{|}~\t\n'，所以不設 filter 的話就會把大部分的標點符號去掉了。

無標點符號的準確率在 Kaggle 上為：

Public: 0.80464

Private: 0.80539

較有標點符號的 model 差，表示句子裡的標點符號也跟情緒有一定的關係。

5. **(1%) 請描述在你的 semi-supervised 方法是如何標記 label，並比較有無 semi-surpervised training 對準確率的影響。**

答：

先 train 完第一題的 RNN 後，用這個 model predict “training_nolabel.txt”，得到每個句子的預測值，若預測值大於 0.5，則標記為 1，若小於 0.5，則標記為 0，再用“training_nolabel.txt”和新增的標記再丟到同個 model train 一次。

訓練過程如下：

丟到 Kaggle 上的準確率為：

Public: 0.80882 Private: 0.80905

較第一題 RNN 的結果差。